Feature Engineering, Entrenamiento y despliegue

Mateo Monsalve Valencia

Septiembre de 2026

Entrega

- Feature engineering sin variables con fuga de información.
- Modelo baseline heurístico.
- Entrenamiento e hiperparametrización con TPE (*Tree-Structured Parzen Estimator*).
- Creación y empaquetado mediante configuraciones.
- Historial de inferencias para monitorear drift con PostgreSQL y Heroku.

Convención de decisión

Clase de incumplimiento = **0**

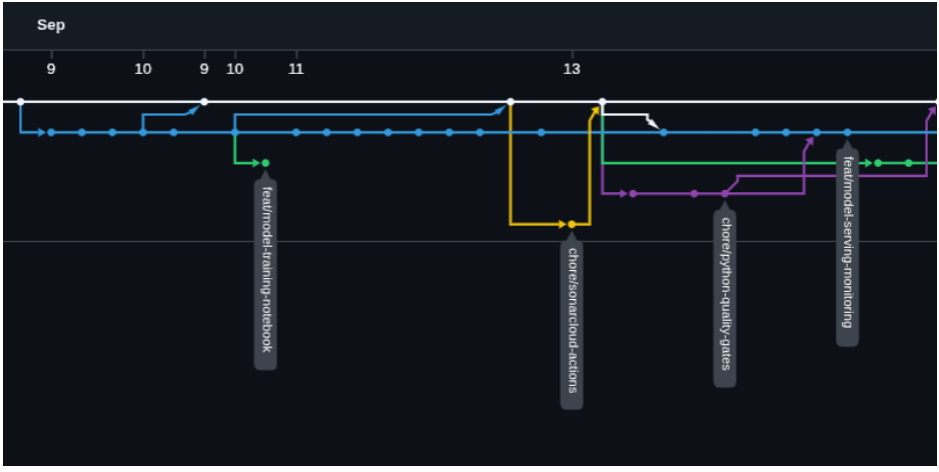
Probabilidades = **[P(incumplimiento), P(a tiempo)]**

La selección usa únicamente validación temporal.

Grafo Git


PR #2
Feature engineering
PR #3 y #5
Baseline y entrenamiento
PR #6-8
Calidad, servicios y monitoreo
PR #9-13
TPE, showcase, estructura y reporte
PR #14
Corrección de presentación

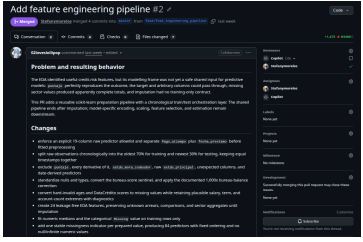
Ramas del repositorio



Pull requests

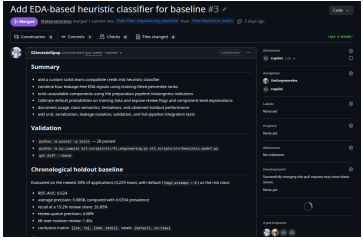
PR #2

Add feature engineering pipeline



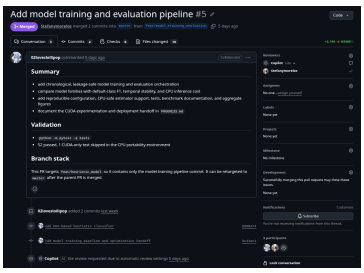
PR #3

Add EDA-based heuristic classifier for baseline

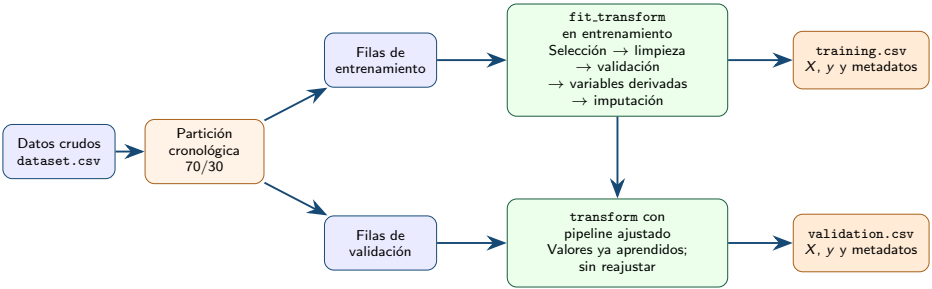


PR #5

Add model training and evaluation pipeline



Feature engineering

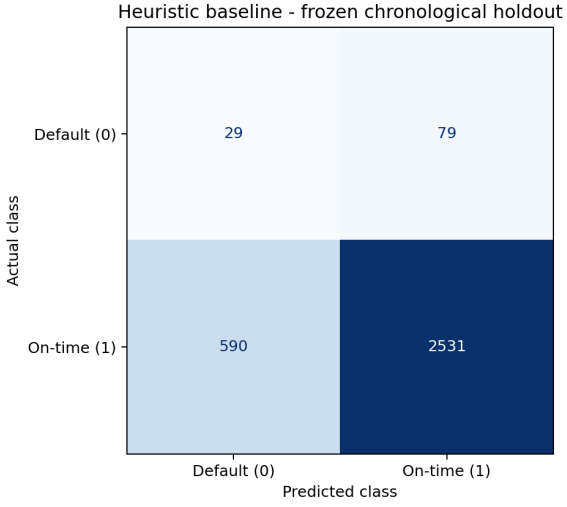


Modelo baseline

Reglas obtenidas del EDA

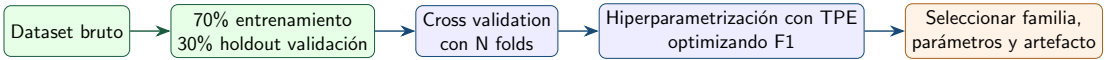
- Alta intensidad de consultas crediticias.
- Bajo puntaje de DataCrédito.
- Desfase entre ingreso declarado y buró.
- Mora registrada en el historial.

Métrica en holdout congelado	Heurístico
Precisión incumplimiento	0.0468
Recall incumplimiento	0.2685
F1 incumplimiento	0.0798
Precisión promedio	0.0858
ROC-AUC	0.6241



Evaluación: holdout de 3.229 filas; incumplimiento: 3,34%.

Entrenamiento



- Métrica objetivo: F1 de incumplimiento.
- Desempate: estabilidad temporal, variación entre semillas de entrenamiento y costo de inferencia en CPU.
- Calibración de probabilidades y selección de umbral con puntajes Out-of-Fold (OOF).

Modelos y TPE

Modelos evaluados

- Regresión logística, árbol, Gaussian NB y SVM RBF.
- Random Forest, Extra Trees, XGBoost y LightGBM.
- MLP de PyTorch.

Referencias

- Baseline heurístico.
- Dummy: estrategia `constant`, clase fija 1 (pago a tiempo).

Búsqueda TPE

- 30 intentos por modelo.
- Seed TPE 20260910: generación pseudoaleatoria de intentos.
- Logística: C y pesos; Gaussian NB: `var_smoothing`; SVM: C, `gamma` y pesos.
- Árboles: profundidad, hojas, estimadores, variables por split y pesos.
- Gradient boosting (XGBoost/LightGBM): estimadores, profundidad/hojas, tasa de aprendizaje, muestreo, columnas, regularización y balance.
- MLP: capas, tasa de aprendizaje, dropout, lote, épocas y regularización.

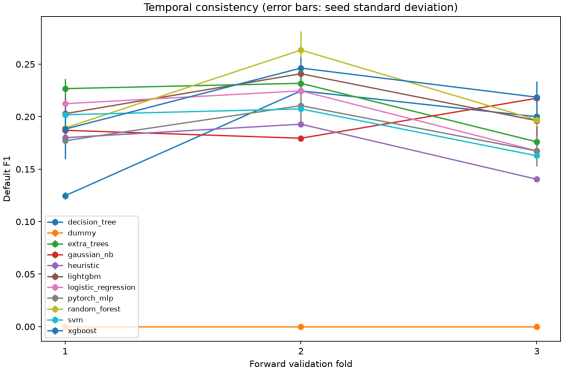
Resultados TPE

Modelo	F1	desv. temporal	AP	ROC-AUC	lote CPU ms
Random forest	0.2166	0.0333	0.1918	0.6987	106.0
XGBoost	**0.2177**	0.0238	**0.2016**	**0.7018**	**44.6**
LightGBM	0.2134	**0.0197**	0.1823	0.6897	52.0
Heuristic	0.1711	0.0223	0.1443	0.6620	52.4

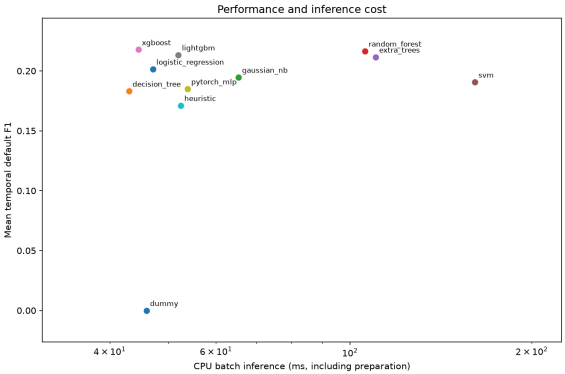
Resultado

XGBoost obtuvo el mayor F1, AP y ROC-AUC, además de la menor latencia en CPU. LightGBM presentó la menor variación temporal. Se desplegó XGBoost.

Comparación de modelos



F1 en validación temporal



F1 frente a costo de inferencia en CPU

Modelo desplegado

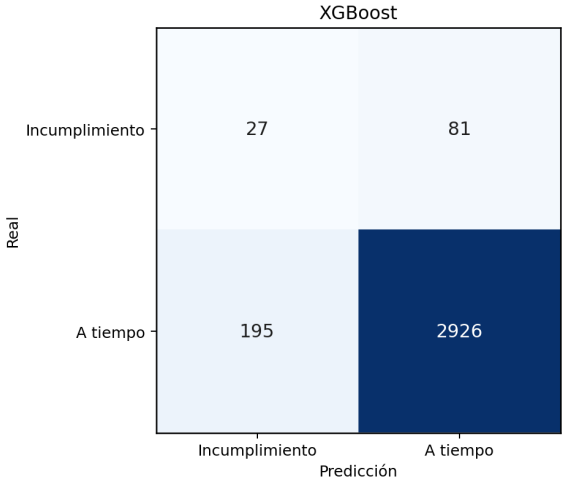
Liberación controlada por configuración

`deployment_model_config.json`: familia, hiperparámetros, orden de clases, CPU y límite de lote. Cambiar el modelo no requiere cambiar la API.

Parámetro	Valor
estimators	1,100
profundidad máxima	5
tasa de aprendizaje	0.00818
peso mínimo de hijo	1.645
submuestra / columnas	0.672 / 0.546
regularización L1 / L2	0.363 / 0.049
ejecución	CPU, orden de clases [0,1]

Métricas XGBoost

Métrica en holdout congelado	XGBoost
Precisión incumplimiento	0.1216
Recall incumplimiento	0.2500
F1 incumplimiento	0.1636
Precisión promedio	0.1052
ROC-AUC	0.6641



Evaluación: holdout de 3.229 filas; incumplimiento: 3,34%.

Stack tecnológico



Python



FastAPI



Dash



SQLAlchemy



PostgreSQL



Docker



Heroku

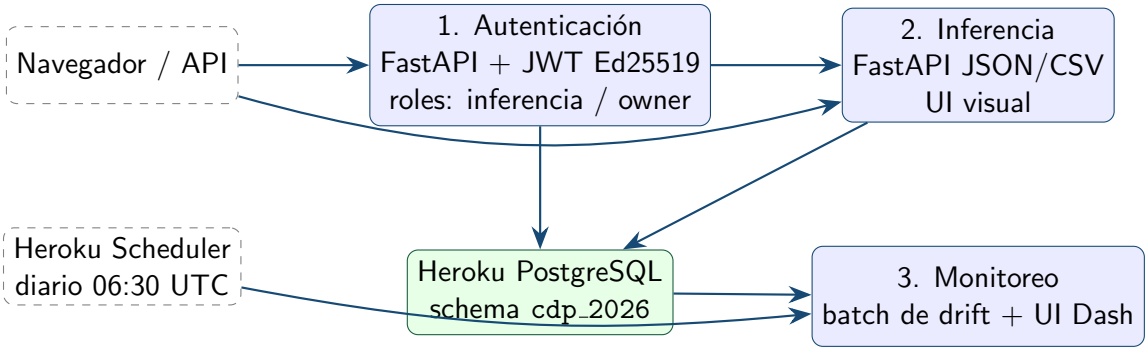


GitHub Actions



SonarCloud

Despliegue

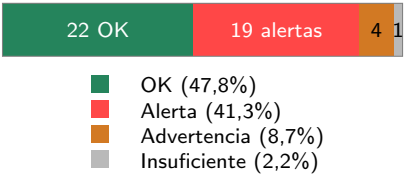

Navegador / API
1. Autenticación
FastAPI + JWT Ed25519
roles: inferencia / owner
2. Inferencia
FastAPI JSON/CSV
UI visual
Heroku Scheduler
diario 06:30 UTC
Heroku PostgreSQL
schema cdp_2026
3. Monitoreo
batch de drift + UI Dash

Monitoreo de drift

Prueba de drift

- 120 filas sintéticas con desplazamiento deliberado.
- 123 predicciones analizadas en la ventana de siete días.
- 46 métricas: **22 ok**, **19 alertas**, **4 advertencias** y **1 dato insuficiente**.

Estado actual de métricas



PSI de la ventana de drift

Variable / señal	PSI	Variable / señal	PSI
Tendencia de ingresos	18.844	Tipo de crédito	17.139
Tipo laboral	17.081	Saldo principal	12.434
Saldo total	11.380	Puntaje DataCrédito	10.506
Probabilidad de incumplimiento	10.435	Promedio de ingresos	9.573
Huella de consulta	9.483	Edad del cliente	9.354

Umbrales del monitor

Advertencia: PSI ≥ 0.10 Alerta: PSI ≥ 0.25

Dashboard de drift desplegado

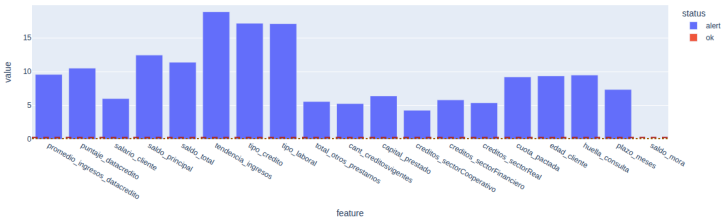
Model monitoring

Batch predictions

Aggregate-only operational view

Overview | Feature drift | Predictions | Performance | Operations

Latest feature PSI



Feature	Metric	Value	Status
promedio_ingresos_datacredito	population_psi	9.57317	alert
promedio_ingresos_datacredito	missing_rate_delta	0.26211	warning

SonarQube SAST

S8544 - bloqueo de dependencias

- Dependencias fijadas a versiones exactas por servicio.
- Hallazgo resuelto.

S8707 - recorrido de rutas por argumento CLI

- El instalador ya no acepta rutas desde `sys.argv`.
- Solo carga el contrato de despliegue del repositorio.
- Hallazgo resuelto.

Servicios desplegados

- Autenticación: `https://auth.cdp2026.02labs.me/`
- API e inferencia visual: `https://api.cdp2026.02labs.me/inference/`
- Dashboard de monitoreo: `https://monitor.cdp2026.02labs.me/monitor/`
- Health checks: `api.cdp2026.02labs.me/health/ready` y `monitor.cdp2026.02labs.me/health/ready`